

Mourad DO-REGO

Data Scientist / AI Engineer - Machine Learning, GenAI & MLOps

Tél : 07 52 06 64 48 | mouwahiddorego@gmail.com | [Linkedin](#) | [Github](#) | [Portfolio](#)

PROFIL

Data Scientist / AI Engineer spécialisé en Machine Learning et GenAI (RAG, LLM). Je conçois des solutions data de bout en bout, du pipeline de données au modèle en production avec Python, LangChain, ChromaDB et FastAPI. Première expérience de mise en production chez Carrefour France (GCP/BigQuery, pipelines automatisés).

PROJETS

- **Biomedical question answering RAG & LLMs : Score global RAGAS 0.792** (Python, LangChain, ChromaDB, Groq/Llama 3.3 70B, FastAPI, Streamlit) : collecte de 652 abstracts PubMed via API (2000 à 2025) sur la santé mentale des jeunes diplômés, 836 chunks indexés dans ChromaDB (embeddings *all-MiniLM-L6-v2*, 384 dimensions), pipeline RAG avec stratégie de fallback, évaluation RAGAS-style, API REST FastAPI + dashboard interactif déployé sur Streamlit.
- **My AI Assistant** : agent IA entraîné sur mon parcours académique et professionnel (Python, Gemini API, FastAPI) : recherche par similarité cosinus en mémoire (sans base vectorielle, choix assumé), expansion du contexte par référence croisée entre chunks liés, génération avec repli à 3 niveaux (Llama 3.3 70B → Llama 3.1 8B → Gemini 2.5 Flash) pour la résilience en production.
- **Prédiction du churn client télécom : Recall 81.6%, gain net estimé 54 500€** (Python, XGBoost, FastAPI, Streamlit, Docker) : EDA sur 7k clients, feature engineering, XGBoost avec optimisation du seuil de décision, explicabilité SHAP, API REST FastAPI dockerisée, dashboard interactif déployé sur Streamlit Cloud.
- **Prévision de consommation énergétique : MAPE 0.74% sur données réelles PJM (145k obs., 2003–2018)** (Python, XGBoost, LSTM, FastAPI, Streamlit, Docker) : feature engineering (35 features : lags, moyennes mobiles, données météo Open-Meteo, encodage cyclique), comparaison 5 modèles (Naïf → Régression Linéaire → LSTM → XGBoost), intervalles de confiance calibrés via Conformal Prediction, prévision itérative H+24, API REST FastAPI sur Render, dashboard monitoring Streamlit Cloud.
- **Optimisation des prix e-commerce : +18.7% de CA via élasticité prix et Machine Learning** (Python, scikit-learn, Power BI) : analyse de 108k commandes, calcul d'élasticité prix par régression log-log, imputation MICE, Random Forest, optimisation scipy, simulation Monte Carlo 10k itérations, dashboard Power BI.

EXPÉRIENCES PROFESSIONNELLES

Data Scientist - Big data & MLOps (GCP)

03/2025 – 09/2025

Groupe Carrefour France

Mondeville, France

- Conception et déploiement d'un pipeline d'automatisation end-to-end mis en production (-35% délais de traitement).
- Déploiement de cas d'usage IA en production avec suivi de la performance et documentation des traitements.
- Requête et exploitation de données massives du datalake via BigQuery pour créer de tables consolidées et historisées.
- Optimisation de requêtes SQL avancées pour alimenter des dashboards de KPI Looker Studio. (-65% à -99% de taux d'erreurs).
- Collaboration transverse avec les équipes métiers pour traduire les besoins en solutions analytiques adaptées.

Data Scientist – Analyse de fraude

05/2024 – 06/2024

Société TEST S.A

Paris, France

- Analyse de données comportementales pour identifier des profils à risque.
- Construction de score de détection de fraude et segmentation de populations.
- Production de reporting analytique pour la prise de décision.

COMPÉTENCES TECHNIQUES

LLM & GenAI : RAG, LangChain, ChromaDB, API (Groq, Gemini), embeddings sémantiques, recherche vectorielle, éval RAGAS
Machine Learning & modélisation : scikit-learn, XGBoost, LightGBM, TensorFlow, NLP, séries temporelles, clustering, arbres de décision, optimisation

Python & Data : pandas, NumPy, Matplotlib, Seaborn, R, SAS

SQL & Data Engineering : BigQuery, GCP, Spark, ETL, Data Warehouse, requêtes avancées, contrôle qualité

Déploiement & MLOps : FastAPI, Docker, Render, Streamlit Cloud, Git, Redis, Prometheus, Grafana, CI/CD.

Visualisation : Power BI, Looker Studio, Streamlit, R Shiny, Excel

FORMATION

Master Méthodologie et Statistique en Recherche Biomédicale

2025 – 2026

Université Paris Saclay

Paris, France

Master Mathématiques Appliquées, Statistiques

2023 – 2025

Université de Caen Normandie

Caen, France

Licence 3 Mathématiques et Informatique Appliquées

2022 – 2023

Université de Caen Normandie

Caen, France

LANGUES

Français – Courant | Anglais – Professionnel