

Mourad DO-REGO

Data Scientist & GenAI Engineer

Tél : 07 52 06 64 48 | mouwahiddorego@gmail.com | [Linkedin](#) | [Github](#) | [Portfolio](#)

PROFIL

Data Scientist & GenAI Engineer, je conçois des solutions data de bout en bout : du pipeline de données jusqu'au modèle en production. Maîtrise de Python (pandas, scikit-learn, XGBoost) et de SQL pour l'extraction et l'optimisation de requêtes, complétée par de solides connaissances en algorithmes et structures de données appliqués à la data science : modélisation prédictive, machine learning, GenAI, LLM, NLP. Mon leitmotiv : transformer des données complexes en solutions concrètes, fiables et utiles à la décision, du prototype jusqu'à la production.

PROJETS

- **Biomedical question answering RAG & LLMs : Score global RAGAS 0.792** (Python, LangChain, ChromaDB, Groq/Llama 3.3 70B, FastAPI, Streamlit) : collecte de 652 abstracts PubMed via API (2000 à 2025) sur la santé mentale des jeunes diplômés, 836 chunks indexés dans ChromaDB (embeddings *all-MiniLM-L6-v2*, 384 dimensions), pipeline RAG avec stratégie de fallback, évaluation RAGAS-style, API REST FastAPI + dashboard interactif déployé sur Streamlit.
- **Prévision de consommation énergétique : MAPE 0.74% sur données réelles PJM (145k obs., 2003–2018)** (Python, XGBoost, LSTM, FastAPI, Streamlit, Docker) : feature engineering (35 features : lags, moyennes mobiles, données météo Open-Meteo, encodage cyclique), comparaison 5 modèles (Naïf → Régression Linéaire → LSTM → XGBoost), intervalles de confiance calibrés via Conformal Prediction, prévision itérative H+24, API REST FastAPI sur Render, dashboard monitoring Streamlit Cloud.
- **Optimisation des prix e-commerce : +18.7% de CA via élasticité prix et Machine Learning** (Python, scikit-learn, Power BI) : analyse de 108k commandes, calcul d'élasticité prix par régression log-log, imputation MICE, Random Forest, optimisation scipy, simulation Monte Carlo 10k itérations, dashboard Power BI.
- **Prédiction du churn client télécom : Recall 81.6%, gain net estimé 54 500€** (Python, XGBoost, FastAPI, Streamlit, Docker) : EDA sur 7k clients, feature engineering, XGBoost avec optimisation du seuil de décision, explicabilité SHAP, API REST FastAPI dockerisée, dashboard interactif déployé sur Streamlit Cloud.
- **Analyse de sentiment NLP : 85% d'accuracy sur 568k avis** (Python, NLTK, scikit-learn, Streamlit) : pipeline NLP end-to-end, nettoyage texte, SVM LinearSVC avec cross-validation, extraction de topics TF-IDF + LDA, dashboard interactif Streamlit.

EXPÉRIENCES PROFESSIONNELLES

Data Scientist - Machine Learning & Big Data (GCP)

Groupe Carrefour France

03/2025 – 09/2025

Mondeville, France

- Conception et déploiement d'un pipeline d'automatisation end-to-end mis en production (-35% délais de traitement).
- Requête et exploitation de données massives du datalake via BigQuery pour créer de tables consolidées et historisées.
- Optimisation de requêtes SQL avancées pour alimenter des dashboards de KPI Loker Studio. (-65% à -99% de taux d'erreurs).
- Collaboration transverse avec les équipes métiers pour traduire les besoins en solutions analytiques adaptées.
- Déploiement de cas d'usage IA en production avec suivi de la performance et documentation des traitements.

Data Scientist – Analyse de fraude

Société TEST S.A

05/2024 – 06/2024

Paris, France

- Analyse de données comportementales pour identifier des profils à risque.
- Construction de score de détection de fraude et segmentation de populations.
- Production de reporting analytique pour la prise de décision.

COMPÉTENCES TECHNIQUES

Python & data science : pandas, scikit-learn, NumPy, Matplotlib, Seaborn, XGBoost, LightGBM, TensorFlow, LangChain, ChromaDB.

LLM & GenAI : RAG (Retrieval-Augmented Generation), Groq API (Llama 3.3 70B), embeddings sémantiques, évaluation RAGAS.

SQL : Rédaction et optimisation de requêtes avancées (BigQuery, Redshift), extraction de données multi-sources, contrôle qualité.

Algorithmes & structures de données : Arbres de décision, NLP, séries temporelles, clustering, optimisation, recherche vectorielle.

Visualisation & communication : Power BI, Loker Studio, Streamlit, R Shiny, Excel.

Déploiement & MLOps : FastAPI, Docker, Render, Streamlit Cloud, Git, Redis, Prometheus, Grafana, CI/CD.

Autres : R, SAS, GCP, Spark, ETL, Data Warehouse, Biopython/PubMed API.

FORMATION

Master Méthodologie et Statistique en Recherche Biomédicale

Université Paris Saclay

2025 – 2026

Paris, France

Master Mathématiques Appliquées, Statistiques

Université de Caen Normandie

2023 – 2025

Caen, France

Licence 3 Mathématiques et Informatique Appliquées

Université de Caen Normandie

2022 – 2023

Caen, France

LANGUES

Français – Courant | Anglais – Professionnel